

GRPO 的收缩基线：JAMES-STEIN 何时塌缩，以及要测出差别需要什么

杨瀚文 (Hanwen Yang)

hanwenya150@gmail.com

代码与日志: https://github.com/hyang150/GRPO_JS_Eva

ABSTRACT

GRPO 只用同一个 prompt 采出的 N 条回答来估计该 prompt 的基线， N 小时这个均值噪声很大。给定的规范提出用 James-Stein 估计量把每个组均值向 batch 均值收缩，其收缩常数由“每样本奖励方差为 1”的假设固定。我们实现了该规范，把五个对照基线放进同一个注册表，并在 Qwen2.5-0.5B-Instruct / GSM8K 上测量。三个结果。(i) 直接作用于原始 0/1 奖励时，规范指定的估计量塌缩成全局 batch 均值：它假设的方差至少高估真实方差 4 倍，塌缩随 prompt 数 K 单调加剧，且在 $N = 2$ 时对一切 $K > 6$ 是一个代数恒等式。三个种子的训练中，它在 100% 的步上丢弃了组结构。(ii) 满足规范自己的 $\sigma^2 \approx 1$ 前提后，Stein 的行为得到恢复：收缩因子与闭式解 $N\tau^2/(1 + N\tau^2)$ 相差不超过 0.02，基线的均方误差在仿真中下降 16–54%。(iii) 以上任何一点在这个规模下都无法体现为端到端精度。在 $K = 32, N = 2$ 下两条可证明为同一算法的臂，三个种子分别相差 0.5、6.5、1.5 个点，而文献报告的效应是 0.65–1.5 个点；逐步梯度噪声/信号比对所有基线都在 58–182。早先草稿报告为显著的配对梯度方差测量，因发现投影 bug 和 off-policy 采样器而撤回，且受时间限制未重做。我们还证明，规范中可选的“除以组内标准差”在任何收缩基线下都会把退化组的优势放大 10^4 倍。

1 引言

Group Relative Policy Optimization (Shao et al., 2024) 把 PPO (Schulman et al., 2017) 的 critic 去掉，改为对每个 prompt 采样 N 条回答，用它们的平均奖励做基线。在可验证的 0/1 奖励和小 N 下，这个基线很粗糙： $N = 2$ 时它只有三个取值，而全对或全错的组根本没有信号。本工作拿到的规范 (GRPO.md, 见附录 A) 给出一个来自经典统计的补救：把一个 batch 里的 K 个组均值看作 K 个共同已知方差 $V = 1/N$ 的正态均值，用正部 James-Stein 估计量 (James & Stein, 1961) 向全局均值收缩。Stein 的结果保证总均方误差更低，规范由此推出优势方差更低、训练更稳、可以支持更小的 N 。

我们把这条推理链从头到尾检验了一遍。贡献如下：

- 六个基线的注册表 (第 4 节)，规范的逐字转录与实现在 10^{-12} 内一致，一个到 verl 优势估计器接口的适配器，162 个测试。规范自带的伪代码在它的文字声称能处理的两个边界情形上崩溃 (附录 B)。
- 对规范估计量何时退化为全局均值的分析 (第 3 节)：收缩项的大 K 极限、 $N = 2$ 恒等式，以及前提满足时收缩因子遵循的闭式解。
- 真值已知的仿真 (第 5.1 节) 和 $K \cdot N = 64$ 的两种组形状、三个种子的 GRPO 训练 (第 5.3 节)，其中包含一对同算法复制实验，直接测出了该协议的噪声底。
- 一份修正记录 (附录 C)：off-policy 采样器、补全 mask 缺陷和梯度投影 bug，都在复查中发现、都已修复，并撤回被它们污染的结果。

主要结论在两个意义上是否定的。规范按原样写法在 0/1 奖励上不工作；修正后的版本虽然对基线做到了 Stein 定理所说的事，但没有产生这个规模的实验能分辨的精度效应。

2 背景

GRPO。 对 prompt x , 策略采样 N 条回答 $y_1, \dots, y_N$, 得到奖励 r_i 。GRPO 构造逐样本优势 $A_i = r_i - b$, b 为组均值, 可选地再除以组内标准差, 然后套用 PPO 的裁剪目标并对参考策略加 KL 惩罚。减去一个不依赖于样本的基线不改变策略梯度的期望但降低其方差; 组均值是价值函数的逐 prompt 蒙特卡洛估计, 这正是 GRPO 不需要 critic 的原因。它并不独立于 r_i (它包含 r_i), 但对普通均值而言这只是把梯度乘以 $(1 - 1/N)$; RLOO (Ahmadian et al., 2024) 的留一均值把这一点也去掉了。

规范。 记组均值 $X_k = \frac{1}{N} \sum_i r_i^{(k)}$, 全局均值 $\bar{X}$, $S = \sum_k (X_k - \bar{X})^2$, $c = V(K - 3)$,

$$\tilde{\mu}_k = \bar{X} + \text{shrink} \cdot (X_k - \bar{X}), \quad \text{shrink} = \max\left(0, 1 - \frac{c}{S}\right), \quad (1)$$

优势为 $A_i^{(k)} = r_i^{(k)} - \tilde{\mu}_k$ 。规范取 $V = 1/N$, 这在每样本奖励方差 $\sigma^2 = 1$ 时是正确的, 并在理论部分说明奖励应先缩放到满足该条件。它的伪代码直接使用原始奖励矩阵。

3 分析

3.1 前提, 以及 K 是什么

GSM8K 的奖励是二值的, 所以 $\sigma_k^2 = p_k(1 - p_k) \leq \frac{1}{4}$: 比假设的至少小 4 倍, 跨 prompt 异方差, 且对全对或全错的组恰好为零 (我们的运行中 $N = 8$ 时占 25-28% 的组, $N = 2$ 时占 68-70%)。高估 V 就高估 c , 把 shrink 推向零。

K 是计算优势时手头有奖励的 prompt 数, 即 rollout batch, 而不是反向传播的 micro-batch。Stein 现象在收缩中心固定时需要 $K \geq 3$, 中心为估计出的全局均值时需要 $K \geq 4$, 所以常数里是 $K - 3$ 。本工作跑 $K = 8$ 和 32; Zeng et al. (2025) 用 64; 生产训练通常是几百到几千。

3.2 大 K 极限

由 $\mathbb{E}[S] \approx (K - 1) \text{Var}(X_k)$ 与 $c = V(K - 3)$, 记 τ^2 为各 prompt 真实通过率的方差,

$$\frac{c}{S} \xrightarrow{K \rightarrow \infty} \frac{V_{\text{assumed}}}{\text{Var}(X_k)} = \frac{V_{\text{assumed}}}{\tau^2 + \sigma^2/N}, \quad (2)$$

是一个常数。 K 不会让收缩更强, 只会让 S 的噪声更小, 于是估计量收敛到这个比值决定的行为。

如果前提成立, $V_{\text{assumed}} = 1/N$ 是精确的, 极限为 $1/(1 + N\tau^2) < 1$, 对任何 N 与 τ^2 都成立: 截断永远不触发, 且

$$\text{shrink} \xrightarrow{K \rightarrow \infty} \frac{N\tau^2}{1 + N\tau^2}, \quad (3)$$

即经验贝叶斯后验权重——温和的收缩, 随 N 增大或 prompt 间差异变大而减弱。

如果前提不成立, 如 0/1 奖励, 该比值至少为 $(1/N)/(\tau^2 + 1/(4N))$ 。对第 5.1 节使用的奖励分布, 它在 $N = 8$ 时为 1.69, $N = 2$ 时为 3.57。超过 1 时正部截断触发, 估计量就是全局均值。更大的 K 让这一点从偶然变成必然: 规范指定的方法随 batch 中 prompt 增多而变差, 而这正是 GRPO 的部署 regime。

3.3 $N = 2$ 恒等式

0/1 奖励的组均值落在 $[0, 1]$, 因此对任何 K 有 $S \leq K/4$ 。当 $c = (K - 3)/N$ 时, 只要 $(K - 3)/N > K/4$, 即 $K > 3/(1 - N/4)$, 截断必然触发: $N = 2$ 时 $K > 6$, $N = 3$ 时 $K > 12$, $N \geq 4$ 时不再有保证, 那时需要 S 足够小, 而这由式 (2) 随 K 增大提供。于是在规范所针对的 $N = 2$ regime 下, 规范指定的估计量对任何多于六个 prompt 的 batch 都等于全局均值, 与奖励取值无关。第 5.3 节把这一点变成了一个测量。

名称	基线 $b[k, i]$	角色
vanilla	组均值	GRPO, 现任方法
rloo	留一组均值	无偏的方差缩减对照
global	batch 均值	消融: 过度收缩退化到的极限
js_fixed	式 (1), $V = 1/N$	规范原样
js_pooled	式 (1), V 由数据估计	规范作用于 r/σ_{pooled} 后缩放回来
js_loo	两级留一收缩	Zeng et al. (2025)

Table 1: 基线。没有 global 这个对照, 比较无法解释: ”James-Stein 有效” 和 ”任何非组均值的基线都有效” 分不开。

N	退化组	global	js_fixed	js_pooled	js_loo	js_pooled shrink (式 3)
2	64.5%	-39.6%	-39.6%	-54.4%	-51.3%	0.386 (0.370)
4	36.7%	+17.2%	+17.2%	-40.8%	-40.0%	0.547 (0.541)
8	18.7%	+131.1%	+131.0%	-26.7%	-27.0%	0.705 (0.702)
16	8.9%	+355.5%	+258.8%	-15.8%	-16.0%	0.827 (0.825)

Table 2: 基线相对真实 p_k 的 MSE, 以 vanilla 为基准的相对值, $K = 32$ 。rloo 与 vanilla 完全相同: 留一改变的是基线的独立性, 不是点估计。最后一列是 js_pooled 实测的收缩因子, 括号内为式 (3) 的预测。

3.4 即便前提成立也不能迁移的东西

三件事。Bernoulli 奖励是异方差的, 所以”共同已知的 V ” 只是靠合并得到的近似; 逐组标准差不可用, 因为三分之一到三分之二的组标准差为零。收缩后的基线通过 $\bar{X}$ 和 S 依赖 r_i 本身, 所以策略梯度有偏——不是普通 GRPO 那种常数因子 $(1 - 1/N)$, 而是非线性的; 只有留一构造能保持无偏。退化组按设计得到非零优势, 把全对的 prompt 往上推、全错的往下推, 方向取决于 batch 碰巧偏向哪边: 这是拿噪声换偏差, 不是凭空造出信号。

3.5 标准差选项

规范提供”之后再除以组内标准差”作为可选项。普通 GRPO 在退化组上这样做是安全的, 仅仅因为那里优势恰好为零, $0/(0 + 10^{-4}) = 0$ 。任何收缩基线都会给这样的组非零优势——这正是方法的意图——于是同一个表达式把它乘以 10^4 。在 GSM8K $K = 8$ 、 $N = 8$ 、38% 退化组下实测: $\text{Var}(A) = 1.07 \times 10^5$, 梯度范数 1.7×10^3 ; 对零离散度的组不缩放则为 0.57 和 1.2。下面所有实验都不做标准差缩放, 这也是 Dr.GRPO (Liu et al., 2025) 从另一个角度主张的选择。

4 估计量

表 1 列出六个基线。js_pooled 是把奖励除以合并组内标准差 $\sqrt{\text{mean}_k s_k^2}$ 后套用规范的十步, 再缩放回去; 这一恒等关系由测试固定在 3×10^{-16} 以内。我们把它读作”满足了自身前提的规范”, 而不是另一个方法。js_loo 遵循 Zeng et al. (2025) 第 3.3 节的式 10 与 13-16, 组均值和收缩目标都是留一的。注册表仿照 verl 的优势估计器接口, 任何一臂都能通过一个薄适配器放进该框架。训练循环把一切可能混淆基线比较的东西固定住: 无 KL 项 ($\beta = 0$, 不加载参考模型)、不做标准差缩放、常数损失归一化使补全长度不会重新加权更新。

5 实验

5.1 真值已知的仿真

GSM8K 上没有真值, 因此基线的误差在仿真中测量: $p_k \sim \text{Beta}(1.2, 2.2)$ (均值 0.35, 与模型观察到的逐 prompt 分布相符; $\tau^2/\sigma^2 = 0.294$), 奖励 $\sim \text{Bernoulli}(p_k)$, $K = 32$ 时 2000 次试验, K 扫描中每个 K 3000 次。

K	js_fixed shrink	js_fixed MSE	global MSE	js_pooled MSE
4	0.333	+1.0%	+99.1%	-9.3%
8	0.058	+84.3%	+116.4%	-18.7%
16	0.006	+121.7%	+125.5%	-24.4%
32	0.000	+130.2%	+130.5%	-26.8%
64	0.000	+133.6%	+133.6%	-28.1%

Table 3: $N = 8$ 下扫描 K 。到 $K = 64$ 时 js_fixed 与 global 每一位都相同。 $K = 4$ 时规范方法大致中性，所以小 K 的实验看不出问题。

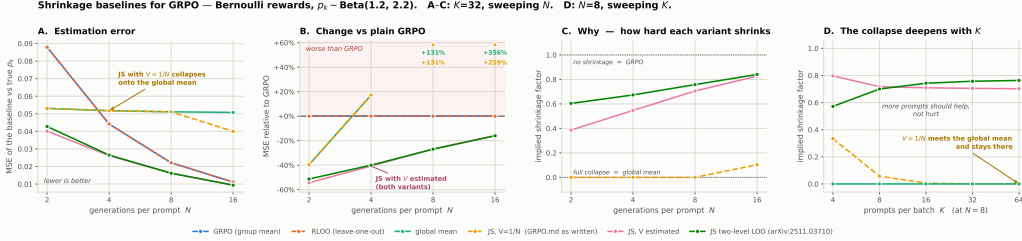


Figure 1: A-C: $K = 32$ 下扫描 N ; D: $N = 8$ 下扫描 K 。js_fixed (虚线) 落在 global 上；估计 V 恢复了预期行为。

表 2 给出 N 扫描。js_fixed 在 $N \leq 4$ 时就是 global， $N = 8$ 时相差不到 0.1%：它完全丢弃了组结构，且 $N \geq 4$ 时比普通 GRPO 更差。估计 V 修复了这一点，增益随 N 减小而增大，正是方法宣称的 regime；实测收缩因子与式 (3) 相差不超过 0.02。表 3 显示塌缩随 K 单调加深，与式 (2) 的预测一致。图 1 画出两者。

5.2 GSM8K 上的 GRPO

Qwen2.5-0.5B-Instruct (Qwen Team, 2024) 全参微调，GSM8K (Cobbe et al., 2021) 规则正确性奖励，512 个新 token，bf16 加梯度检查点，学习率 10^{-6} ，PPO 裁剪 0.2，每次 rollout 一次内层更新。开发在一张 RTX 5080 上 (16 GB；峰值 11.0 GiB， $K=8, N=8$ 下约 25 秒一步)，三种子扫描在两张 RTX 5090 上。每次评测都按相同顺序贪心解码同样的 200 道测试题，因此 checkpoint 之间用 McNemar 检验比较，而不是看二项区间是否重叠。

两个工程细节影响数字。梯度检查点会置 use_cache=False，悄悄让生成成长度的二次复杂度；在 rollout 前后切换它使每步时间减半。纯 bf16 在 10^{-6} 下会把大部分更新舍入掉——权重 0.0145 的 ULP 是 1.1×10^{-4} ，而一步 AdamW 只移动约 10^{-6} ；实测每步只有 2.3% 的采样权重发生变化。fp32 主权重方案在这个 batch 下放不进 16 GB，所以各臂共同承担 bf16 的劣势。

5.3 三个种子，两种组形状

两种形状各四臂， $K \cdot N = 64$ ，每臂每步看到同样多的补全；同一种子的各臂走同一条 prompt 流。结果见表 4。

$K = 8, N = 8$ 下什么都分不出来。每臂与 vanilla 相差不超过 1.2 个点，每个 sem 都大于差值，每个 p 都在 0.6 左右。逐种子那一列说明了原因：同一臂在种子之间移动 3-5 个点。只看种子 0 会得出 global 比 vanilla 高 4.0 个点 (McNemar $p = 0.039$)；种子 1 和 2 分别给出 +2.0 和 -2.5。

$K = 32, N = 2$ 下唯一显著的那一行就是噪声底。js_fixed 的 -3.0 ± 0.3 ($p = 0.009$) 读起来像个发现。但由第 3.3 节，在这个形状下它就是 global：三个种子全部 150 步记录的收缩因子都是 0，第 1 步的记录与 global 逐位一致，两个进程从第 2 步起才因 GPU 采样生成不可复现而分开。所以这两臂是同一算法在同种子下的三对复制 (表 5)：它们最终相差 0.5、6.5、1.5 个点。把它们当作同一算法的六次运行合并，对 vanilla 是 -1.6 ± 1.0 ，显著性消失。自由度 2 的 t 检验遇上三个碰巧落在 0.5 以内的差值，可以凭空产生 $p < 0.01$ 。

$K \times N$	臂	各种子最终精度	均值 $\pm$ sem	对 vanilla	p	shrink	塌缩步数
8 $\times$ 8	vanilla	44.5 / 42.0 / 47.5	44.7 $\pm$ 1.6			1.000	0
8 $\times$ 8	js_pooled	44.0 / 45.5 / 47.0	45.5 $\pm$ 0.9	+0.8 $\pm$ 1.3	0.60	0.85	0–1
8 $\times$ 8	js_fixed	44.0 / 47.5 / 46.0	45.8 $\pm$ 1.0	+1.2 $\pm$ 2.2	0.65	0.21	38–44
8 $\times$ 8	global	48.5 / 44.0 / 45.0	45.8 $\pm$ 1.4	+1.2 $\pm$ 1.9	0.61	0.000	150
32 $\times$ 2	vanilla	46.0 / 45.5 / 44.5	45.3 $\pm$ 0.4			1.000	0
32 $\times$ 2	js_pooled	41.0 / 46.0 / 47.5	44.8 $\pm$ 2.0	−0.5 $\pm$ 2.4	0.85	0.56	0–1
32 $\times$ 2	js_fixed	43.5 / 42.0 / 41.5	42.3 $\pm$ 0.6	−3.0 $\pm$ 0.3	0.009	0.000	150
32 $\times$ 2	global	44.0 / 48.5 / 43.0	45.2 $\pm$ 1.7	−0.2 $\pm$ 1.6	0.93	0.000	150

Table 4: 150 步后的最终测试精度 (200 题, 贪心), 种子 0–2, 修正后的采样器。”对 vanilla” 为同种子内的配对差, p 为自由度 2 的配对 t 检验, shrink 为隐含收缩因子的运行均值, ”塌缩步数” 为恰好等于 0 的步数 (跨种子范围)。所有运行从同一 checkpoint 出发, 因此 24 次运行第 0 步精度都是 45.0%。

种子	global	js_fixed	差值
0	44.0%	43.5%	+0.5
1	48.5%	42.0%	+6.5
2	43.0%	41.5%	+1.5

Table 5: 同一算法在每个种子下跑两次 ($K = 32, N = 2$)。这个离散就是本协议的 run-to-run 项。早先在 1.1 采样器下的两次运行估计为 3.0 个点。

这一设定下文献报告的效应是 0.65–1.5 个点 (Zeng et al. (2025) 表 2: 同模型同任务, $N = 8/4/2$ 下 JS 减 GRPO, $K = 64$, 500 步, 五个种子)。噪声底是效应的 2–5 倍; 在这样的离散下分辨一个点的效应, 每臂需要大约 20–40 个种子。

扫描确实确立了什么。 规范原样在它所针对的 $N = 2$ 下, 在 100% 的步上丢弃了组结构 ($N = 8$ 时为 25–30%); js_pooled 在 $N = 2$ 时保留 56%、 $N = 8$ 时保留 85%, 即 Stein 结果所要求的温和收缩。”训练更稳” 的说法得不到支持: 没有任何一臂裁剪过任何一步梯度, 采样 token 熵对所有臂一样从 0.52 降到 0.26–0.33, 逐步梯度噪声/信号比 (Zeng et al. (2025) 式 17–18, 跨 micro-batch) 在 58–182, 且 32–45% 的步返回非正的信号估计。每步 8 或 32 个 prompt 时, 梯度对每个基线都几乎全是噪声, 这个比值分不开它们。这些步作为右删失 ($+\infty$) 报告而非丢弃, 丢弃会把中位数往下拉。图 2 显示两种形状的种子 0。

5.4 一项撤回的测量

因为训练运行分辨不了效应, 早先的草稿直接测量估计量: 所有基线对同一批冻结策略的 rollout 打分, 用 Hutchinson 探针估计梯度协方差的迹除以 $\|\mathbb{E}[g]\|^2$, 在 200 个 batch 上 bootstrap。它报告 js_loo 相对 GRPO 为 −21.4% [−51.5, −7.8]。两个缺陷使其无效: 探针在形状相同的参数张量之间复用了随机数, 且所有 rollout 都用 checkpoint 默认的 1.1 重复惩罚采样, 而不是从策略本身采样 (附录 C)。这个仪器本身也脆弱: $\|\mathbb{E}[g]\|^2$ 只占 $\mathbb{E}\|g\|^2$ 的 8%, 还是作差得到的。投影已修复, 并加入了不依赖探针的估计器——对独立的 batch, $\mathbb{E}\langle g_b, g_{b'} \rangle = \|\mathbb{E}[g]\|^2$ 精确成立, 所以不相交的 batch 对给出两个量的无偏样本——两者都在模拟梯度上通过了测试。受时间限制, 这项测量没有在模型上重做。历史表格放在附录 E, 作为仪器的记录而非证据。

6 相关工作

Zeng et al. (2025) 是同一思路但把前提处理好了: 组内方差和 prompt 间方差都从 batch 估计, 两层都是留一的所以策略梯度保持无偏, 且没有超参数。这就是这里的 js_loo。他们报告在同模型同任务、 $K = 64$ 下比 GRPO 高 0.65–1.5 个点, 梯度方差低 11–67%。EBPO (Han et al., 2026) 走经验贝叶斯路线: 向一个在线维护的全局先验而不是 batch 均值收缩, 收缩强度由组内/组间方差比决定。它宣称的特性——全零组仍得到非零信号——正是第 3 节归为偏差的那个机制。Efron & Morris (1975) 把 James–Stein 用于二项比例, 正是 0/1 奖励




Figure 2: 种子 0, $K=8, N=8$ (上) 与 $K=32, N=2$ (下)。奖励和退化组两个面板重叠；收缩面板把各臂分开, $N=2$ 时 `js_fixed` 整个运行都落在 `global` 的零线上。没有任何梯度范数达到裁剪阈值。

的情形；他们对 $\sigma^2 \neq 1$ 的处理是在收缩前做反正弦平方根方差稳定变换。我们改用合并组内标准差；那个变换是更正统的路线，这里没有尝试。RLOO (Ahmadian et al., 2024) 与 Dr.GRPO (Liu et al., 2025) 分别是 `rloo` 对照和”默认不缩放”的依据。

7 局限与结论

两种组形状各三个种子，每个精度差值都落在自己的标准误内，同算法对相差 0.5–6.5 个点；两个方向上都不做精度声明。配对梯度方差测量是这个规模下唯一可能分开各基线的仪器，它已撤回且未重做。`rloo` 和 `js_loo` 没有进入三种子扫描。单一模型、单一任务；塌缩阈值是否随奖励密度移动未经测试。

本工作确立的东西在其精确之处是精确的。规范指定的估计量按其伪代码作用于 0/1 奖励时就是全局 batch 均值——对任何 N 在 K 趋于无穷时渐近成立，对 $N=2$ 在一切 $K > 6$ 下恒等成立——训练日志也显示了这一点。满足规范自身的前提后，恢复的是 Stein 定理描述的那个估计量，其收缩因子遵循经验贝叶斯闭式解。这个估计量能否改进训练，是这个规模的实验回答不了的问题；而一个只报告单个种子、或用自由度 2 的 t 检验的协议，会把它答错。

REFERENCES

- Arash Ahmadian, Chris Cremer, Matthias Gallé, Marzieh Fadaee, Julia Kreutzer, Olivier Pietquin, Ahmet Üstün, and Sara Hooker. Back to basics: Revisiting REINFORCE-style optimization for learning from human feedback in LLMs. *arXiv preprint arXiv:2402.14740*, 2024.
- Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John Schulman. Training verifiers to solve math word problems. *arXiv preprint arXiv:2110.14168*, 2021.
- Bradley Efron and Carl Morris. Data analysis using Stein’s estimator and its generalizations. *Journal of the American Statistical Association*, 70(350):311–319, 1975.
- K. Han, Y. Zhou, M. Gao, G. Zhou, S. Li, A. Kumar, X. Fan, W. Li, and L. Zhang. EBPO: Empirical Bayes shrinkage for stabilizing group-relative policy optimization. *arXiv preprint arXiv:2602.05165*, 2026.

Willard James and Charles Stein. Estimation with quadratic loss. In *Proceedings of the Fourth Berkeley Symposium on Mathematical Statistics and Probability*, volume 1, pp. 361–379, 1961.

Zichen Liu, Changyu Chen, Wenjun Li, Penghui Qi, Tianyu Pang, Chao Du, Wee Sun Lee, and Min Lin. Understanding R1-zero-like training: A critical perspective. *arXiv preprint arXiv:2503.20783*, 2025.

Qwen Team. Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*, 2024.

John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.

Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, Y. K. Li, Y. Wu, and Daya Guo. DeepSeekMath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024.

Guanning Zeng, Zhaoyi Zhou, Daman Arora, and Andrea Zanette. Shrinking the variance: Shrinkage baselines for reinforcement learning with verifiable rewards. *arXiv preprint arXiv:2511.03710*, 2025.

A 规范

GRPO.md 依次给出：动机（小 N 的组均值噪声大）；模型 $X_k \sim \mathcal{N}(\mu_k, V)$, $V = 1/N$ ，其前提是奖励已缩放到 $\sigma^2 \approx 1$ ；式 (1) 的正部 James–Stein 估计量， $c = (K - 3)/N$ ；十个实现步骤（组均值、全局均值、 S 、 c 、 $K < 4$ 回退、带 ε 保护的收缩因子、 $S = 0$ 情形、截断、收缩后均值、优势）；一段 Python 伪代码；以及可选的除以组内标准差。

B 与伪代码的一致性

tests/test_spec_conformance.py 转录了十个步骤，并另外逐字转录了 Python 伪代码，两者都对实现运行。在边界情形之外，伪代码与 js_fixed 在连续奖励和 0/1 奖励上都在 10^{-12} 内一致。在它自己的边界情形上，伪代码跑不起来：

输入	伪代码的行为
$K < 4$	<code>IndexError</code> : $\bar{X}$ 是 0 维张量， <code>unsqueeze(1)</code> 越界
$S = 0$	<code>TypeError</code> : Python 的 <code>max(S, eps)</code> 在 $S < \varepsilon$ 时返回 float <code>eps</code> , <code>torch.clamp</code> 拒绝 float
$K = 8$ 、 $N = 8$ 、0/1 奖励、 $S > 0$	能运行，且等于 <code>js_fixed</code>

两处偏离，均有断言。步骤 5 的文字在 $K < 4$ 时返回逐组均值；伪代码修好索引后返回的是以全局均值中心化的奖励——即 `global` 臂，不再是 GRPO。我们遵循文字。步骤 7 的“ $S = 0 \Rightarrow$ 收缩因子为 1”在伪代码中不可达；我们改为截断到 0，观测上等价，因为 $S = 0$ 迫使 `diff = 0`。

C 修正

初稿后复查发现，均已在代码中修复。

1. **off-policy rollout (2026-09-04)**。`generate()` 设置了温度、top- p 与 top- k 但没有设置 `repetition_penalty`，于是落到 checkpoint 的 `generation_config`——Qwen2.5-Instruct 为 1.1。补全从带惩罚的分布采样，而损失用的是原始策略的对数概率，每个实验的每一臂都如此。循环现在显式传 1.0。第 5.3 节的三种子扫描在修复之后运行；附录 D 的种子 0 五臂扫描和梯度测量则不是。

2. **投影 bug (2026-09-03)**。Hutchinson 探针在形状相同的参数张量间复用了随机数。已修复（每个探针一条连续随机流）；回归测试把投影协方差与精确协方差比较。
3. **补全 mask (2026-09-04)**。只把 `<|im_end|>` 当作停止 token；Qwen2.5 还会在 `<|endoftext|>` 上停止，而它同时是 pad token，于是这样结束的补全被当成 512 个有效 token 计分，包括 padding。mask 现在在所有终止符加 pad id 上停止。
4. **收缩诊断 (2026-09-04)**。均值等于全局均值的组被记为”未收缩”而不是”未定义”。仿真表已用修正后的诊断重新生成（global 现在显示定义上的 0；MSE 列移动不超过 1.5 个百分点）。

D 1.1 采样器下的种子 0 扫描

第一次扫描，已被取代，留作记录：五臂，150 步，同一种子，同样的 200 道测试题。

臂	eval@0	eval@final	Δ	p	shrink	塌缩
vanilla	42.5%	45.5%	+3.0	0.24	1.000	0/150
js_pooled	42.5%	45.0%	+2.5	0.27	0.850	1/150
js_loo	42.5%	45.5%	+3.0	0.21	0.818	0/150
js_fixed	42.5%	47.0%	+4.5	0.11	0.202	64/150
global	42.5%	47.5%	+5.0	0.06	0.025	133/150

没有任何显著结果；五臂之间 2.5 个点的离散低于单臂对自身的噪声底。收缩列分成精度分辨不出的几层，独立推导的 js_pooled 与 js_loo 相差不超过 0.03。global 的 0.025 是附录 C 所述的诊断伪影。这次扫描的裁剪次数（global 150 步中 36 次，vanilla 9 次）和熵差异在修正后的采样器下消失。

E 撤回的梯度测量

200 个配对 batch， $K = 8 \times N = 8$ ，策略冻结，平均精度 29.1%，1.1 采样器，有 bug 的投影。区间为以 24 个探针为条件、在 batch 上的配对 bootstrap。

基线	噪声/信号	对 GRPO
vanilla	11.5	—
rlloo	11.5	-0.3% [-2.5, +6.9] 仪器检查
js_loo	9.1	-21.4% [-51.5, -7.8] 撤回
js_pooled	9.9	-14.4% [-38.2, +0.8] 撤回
js_fixed	6.0	-48.1% [-81.3, -15.8] 有偏估计量
global	5.8	-49.7% [-83.5, -15.6] 有偏估计量

即便这些数字成立，js_fixed 和 global 也不是”最好”：它们瞄准的是另一个 $\mathbb{E}[g]$ ，因为给全对的组一个正优势会用一个只是把简单题往上推的分量抬高 $\|\mathbb{E}[g]\|^2$ 。分母更大不等于信号更多。

F 复现

```
uv sync && python main.py smoke
python -m pytest tests/ -q # 162 tests
python main.py synthetic --k 32 --n 2 4 8 16
python experiments/synthetic_mse.py --k 4 8 16 32 64 --n 8 \
  --trials 3000 --out results/synthetic_k_sweep.json
python main.py sweep --seeds 0 1 2 --k 32 --n 2 --track-grad-var \
  --baselines vanilla js_fixed js_pooled global
python main.py sweep --seeds 0 1 2 --k 8 --n 8 --track-grad-var \
  --baselines vanilla js_fixed js_pooled global
python main.py compare --glob 'train_*k8n8_s*.jsonl'
python main.py compare --glob 'train_*k32n2_s*.jsonl'
```

```
python main.py figures
```

第 5.3 节的 24 份逐步日志已提交在 `results/` 下；它们无法逐位复现（第 5.3 节），这正是保留它们的原因。